

Prediksi IHSG Dengan Algoritma Autoregressive Integrated Moving Avarage (ARIMA)

Roby Ibrahim^{1*}, Yoga Handoko Agustin²

^{1,2}Institut Teknologi Garut, Indonesia

***email:** 1906130@itg.ac.id

Info Artikel	ABSTRAK
Dikirim: 3 September 2023 Diterima: 14 April 2024 Diterbitkan: 30 November 2025	Perkembangan pasar modal merupakan salah satu indikator utama perekonomian suatu negara. Oleh karena itu, kemampuan memprediksi pergerakan Indeks Harga Saham Gabungan (IHSG) sangat penting bagi investor dan pelaku pasar modal. Tujuan dari penelitian ini adalah mengembangkan model IHSG dengan menggunakan algoritma <i>Autoregressive Integrated Moving Average</i> (ARIMA) dengan dukungan <i>software RapidMiner</i> . Hasil uji simulasi menunjukkan bahwa model ARIMA dapat menjadi alat yang berguna bagi investor dan peneliti pasar untuk mengambil keputusan yang lebih bermakna. Metodologi penelitian yang digunakan adalah CRISP-DM (<i>Cross-Industry Standard Process for Data Mining</i>) meliputi langkah-langkah sebagai berikut: Pertama, pengumpulan data historis IHSG dari periode yang relevan. Kedua, menganalisis <i>time series</i> untuk memahami karakteristik IHSG. Ketiga, menerapkan model ARIMA dengan <i>parameter</i> $(p;2, d;1 q;2)$ dengan MSE 2461.572, menggunakan metode analisis statistik dan mengevaluasi kinerja model. Keempat, menjalankan model ARIMA pada <i>software Colabulatory</i> untuk memprediksi aktivitas IHSG. Kelima, evaluasi performa model menggunakan metrik. Hasil penelitian ini telah berhasil membuat model ARIMA terbaik yang diimplementasikan dengan <i>Colabulatory</i> dan dapat memberikan informasi yang akurat. Penelitian ini menghasilkan model prediksi dengan metrik evaluasi RMSE 1.43 dan MAE 1.13.

1. PENDAHULUAN

Saat ini, wirausahawan memiliki banyak pilihan yang tersedia bagi mereka dalam hal pembiayaan [1]. Jenis investasi bisa bermacam-macam, satu di antaranya adalah investasi saham. Saham adalah hak seseorang dalam suatu perusahaan akibat perpindahan modal sebagian atau seluruhnya. *Investor* mengalokasikan dana pada sekuritas dan berusaha mencapai keuntungan maksimal atas investasinya. Namun, banyak investor yang tidak yakin dengan risiko dalam berinvestasi dan takut bahwa apa yang mereka investasikan tidak sesuai dengan harapan mereka [2]. Keraguan investor mengenai perlunya berinvestasi disebabkan oleh fluktuasi nilai indeks saham dalam periode singkat [3]. Indeks Harga Saham Gabungan, atau IHSG, adalah ukuran yang mencakup semua saham yang terdaftar dalam perhitungan indeks [4]. Sunariyah (2006: 142), IHSG adalah suatu parameter yang dipergunakan untuk mengevaluasi kinerja kolektif saham yang terdaftar di sebuah bursa efek.. Sekarang ini, pemberitaan tentang saham menjadi topik yang umum di media elektronik maupun media cetak. Isu-isu yang berkaitan dengan pergerakan harga saham hingga berbagai berita terkait juga menjadi sorotan [5]. Pergerakan harga saham dari waktu ke waktu sangat kompleks, dipengaruhi oleh berbagai faktor ekonomi yang terjadi di suatu negara. Indeks harga saham digunakan sebagai alat analisis statistik untuk mengukur kondisi terakhir di pasar dan kesehatan ekonomi suatu negara [6]. Presiden KSEI Urieip Budhi Prasetyo mengatakan:

“Peningkatan jumlah investor saham merupakan salah satu penanda pencapaian pasar modal Indonesia.” sebuah tanda bahwa masyarakat Indonesia semakin sadar akan pentingnya berinvestasi dan perubahan alternatif investasi yang dilakukan pasar modal [7].



Gambar 1. Demografi Investor

Pandemi *Covid-19* di Indonesia telah mempengaruhi pasar modal dan menyebabkan perubahan jam perdagangan bursa efek Indonesia [8]. Dalam menunjang keberhasilan penelitian ini, maka penulis merujuk beberapa jurnal yang relevan dengan penelitian ini, yang dijadikan sebagai acuan penelitian. Penelitian rujukan pertama, penelitian ini berfokus pada peramalan harga produksi karet di provinsi Riau. Penelitian ini menggunakan algoritma ARIMA, hasil dari penelitian ini menghasilkan model terbaik dari ARIMA (1,1,2), dan hasil ramalan produsen karet di provinsi Riau selama tahun 2023 mencapai harga 7454,025 (Rp/Kg) dan akan naik terus secara konstan sampai 7541,329 (Rp/Kg) [9]. Penelitian rujukan ke dua, penelitian ini melakukan prediksi harga saham PT.Telekomunikasi Indonesia dengan metode algoritma svm yang ditingkatkan kinerjanya dengan *kernel RBF*. Hasil pengujian menghasilkan Tingkat akurasi 0.9641 dan *RMSE* sebesar 0.945. Pengujian juga dilakukan dengan algoritma KNN dengan Tingkat akurasi 0.945 dan *RMSE* sebesar 0.1162 [10]. Penelitian rujukan ke tiga, penelitian ini melakukan prediksi harga saham *PTBA* dengan dataset dari tahun 2017-2022. Penelitian ini menggunakan metode algoritma *Neural Network* dengan optimasi *hyperparameter*. Hasil dari penelitian ini menunjukkan nilai akurasi 30,636 *RMSE* [11]. Penelitian rujukan ke empat, penelitian ini berfokus pada peramalan harga saham *Netflix* yang akan datang, penelitian ini menggunakan algoritma *Multiple Regression*. Dataset yang diambil mulai dari bulan Januari 2010-30 Maret 2023 dengan jumlah data 3334 data, hasil yang diperoleh dari penelitian ini adalah 0.99% dari hasil pengolahan data dan hasil *RMSE* sebesar 3.73 dari 1334 *data testing* [12]. Penelitian kelima Penelitian ke lima dilakukan, Penelitian ini bertujuan untuk meningkatkan dan memperbaiki dengan mengurangi tingkat kesalahan 5 data saham *Blue Chip* di Indonesia, Dari desain terintegrasi dari 4 *hidden layer Neural Network* menggunakan *Long Short Term Memory* (LSTM) dan *Gated Recurrent Unit (GRU)*. Dataset diambil dari sembilan saham *Blue Chip* Indonesia dari periode 2 Februari 2015 sampai 19 Juni 2020, hasil dari penelitian ini di dapat bahwa saham *Bank BCA* mendapatkan *RMSE* 1120,651, *epoch* = 15, Saham *BBRI*, nilai *RMSE* terkecil yaitu 110,331, *epoch* = 25, Saham *INDF* nilai *RMSE* terkecil yaitu 156,297, *epoch* = 35, Saham *ASII* dengan nilai *RMSE* terkecil yaitu 134,551, *epoch* = 20, Saham *TLKM*, dengan nilai *RMSE* terkecil yaitu 71,658, *epoch* = 35 [13]. Penelitian ke-enam bertujuan untuk mengetahui Prediksi Indeks Harga Saham Gabungan (IHSG) menggunakan Prophet. Metode yang digunakan adalah penelitian penjelasan. Teknik analisis menggunakan Prophet. Hasil penelitian ini menunjukkan akurasi prediksi yang cukup baik dengan *MAPE* sebesar 8.27 dan 4.69 dengan penyetelan hiper parameter; prediksi sedikit kurang baik pada bulan Maret tahun 2020 karena ada kasus pandemi *Covid-19* [14], penelitian ke-tujuh membandingkan hasil metode regresi linier dan pola historis prediksi yang dihasilkan bisa jauh lebih akurat. Dari dataset analisis harga saham *Microsoft* yang diambil sejak tahun 2018-2023 terdapat kesimpulan harga saham terendah *Microsoft* bulan November 2022 sebesar 217,826, saham tertinggi bulan Mei 2023 sebesar 309,948 dan rata-rata harga sebesar 260,787. Dari perhitungan tersebut didapatkan prediksi saham *Microsoft* tanggal 15 Mei 2023 menggunakan regresi linier sebesar 306,976 dan pola historis sebesar 260,136 sehingga terdapat gap 46,84. Dari perbandingan ini, disimpulkan bahwa gap perhitungan manual dengan regresi linier jauh lebih kecil dibandingkan pola historis, dengan selisih masing-masing sebesar 0,054 dan 46,786. Sehingga menegaskan bahwa penggunaan metode regresi linier memberikan prediksi yang lebih akurat dibandingkan pola historis [15]. Berdasarkan beberapa penelitian sebelumnya, dapat disimpulkan bahwa


meskipun model prediktif seperti ARIMA telah digunakan dalam berbagai konteks, belum ada penelitian yang secara khusus mengembangkan model prediksi IHSG dengan mempertimbangkan pengaruh data eksternal seperti *Covid-19* dan menggunakan pendekatan CRISP-DM secara lengkap. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan model prediksi IHSG periode 2018-2023 dengan algoritma ARIMA yang mempertimbangkan data pandemi *Covid-19* serta menggunakan metode CRISP-DM, sehingga dapat memberikan hasil prediksi yang lebih kontekstual dan akurat bagi investor pasar modal Indonesia.. Maka dari itu didapatkan judul penelitian “Prediksi Ihsg Dengan Algoritma *Autoregressive Integrated Moving Avarage* (ARIMA)”

2. METODE PENELITIAN

Menurut [16] CRISP-DM (*Cross-Industry Standard Process for Data Mining*) merupakan suatu metode terstruktur dalam melakukan tugas-tugas penambangan data yang meliputi beberapa langkah utama seperti perencanaan strategis, pengumpulan data awal, penafsiran data, analisis data, pengendalian kualitas data, serta pemilihan, penyaringan, pengorganisasian, integrasi, dan pengorganisasian data untuk persiapan analisis dan penelaahan . Metode ini sangat relevan dalam konteks penelitian karena menyediakan kerangka kerja yang sistematis untuk menangani dan menganalisis data secara efektif, yang memungkinkan peneliti untuk mengidentifikasi pola, tren, dan wawasan yang signifikan dari *dataset* yang kompleks. *Dataset* IHSG diambil dari *Yahoo Finance* menggunakan kode indeks *JKSE*, mencakup periode Januari 2018 hingga Desember 2023. Data ini berisi 1.451 entri harian dengan kolom meliputi *Date*, *Open*, *High*, *Low*, *Close*, *Adj Close*, dan *Volume*. Di sisi lain, data kasus *Covid-19* diperoleh dari Kaggle, yang mencatat jumlah infeksi harian selama tahun 2020 hingga 2022.

2.1 Kerangka Penelitian

Adapun kerangka penelitian dalam pemodelan prediksi IHSG dengan penerapan metode pendekatan CRISP-DM disajikan pada gambar 3.1 berikut :



Gambar 2. Kerangka Penelitian

M1 (*Milestone 1*) = Business Understanding, fokusnya adalah pada pemahaman tujuan dan kebutuhan bisnis. Selain itu, data yang dikumpulkan digunakan sebagai dasar perencanaan rencana awal data mining [17]. M2 (*Milestone 2*) = Data Understanding dimulai dengan pengumpulan data awal dan dilanjutkan dengan kegiatan untuk membiasakan diri dengan data, untuk mengidentifikasi masalah kualitas data, untuk menemukan wawasan pertama ke dalam data [18]. M3 (*Milestone 3*) = Data Preparation menyiapkan data mentah yang digunakan dalam penelitian menjadi set data yang siap digunakan. Proses ini terdiri dari beberapa langkah, dimulai dari pemilihan data, pra-pemrosesan data, dan transformasi data. Langkah-langkah ini dapat diulang hingga format data yang diinginkan untuk tahap pemodelan tercapai [19]. M4 (*Milestone 4*) = Modeling Pemodelan adalah tahap memilih dan menerapkan teknik algoritma yang telah ditentukan dan biasanya menggunakan bantuan kerangka kerja tertentu untuk menghitung data [20]. M5 (*Milestone 5*) = Evaluation adalah Pada tahap evaluasi ini, model yang dihasilkan dianalisa untuk memastikan bahwa desain yang dihasilkan telah sesuai dengan standar yang ada. Pada proses ini, hasil evaluasi model yang dilakukan pada fase sebelumnya diukur [21]. M6 (*Milestone 6*) = *Deployment* adalah di mana dalam fase terakhir ini pemodelan bukanlah akhir dari proyek. Secara umum, pengetahuan yang diperoleh harus diorganisir dan disajikan sedemikian rupa sehingga pengguna dapat menggunakannya. Bergantung pada kebutuhan pengguna [22].

3. HASIL DAN PEMBAHASAN

3.1 Hasil Penelitian

Hasil dari penelitian ini adalah terbentuk model prediksi harga saham IHSG periode 2018-2023 dengan algoritma ARIMA yang berdasarkan metodologi CRISP-DM.

3.1.1 Business Understanding

1. Tujuan model bisnis
Tujuan model bisnis untuk penelitian ini adalah membantu investor saham untuk mengurangi resiko investasi saham yang pergerakan harganya begitu fluktuatif dan membantu dalam menentukan efektifitas keputusan investasi yang telah diambil untuk memperbaiki kinerja dimasa mendatang.
2. Memahami situasi bisnis
Investor perlu mengambil tindakan yang tepat untuk mengurangi resiko kerugian yang ada dengan memahami turun naiknya saham di masa mendatang.
3. Menentukan target *mining*
Tujuan dari *mining* ini adalah untuk mengenali pola atau *trend* dari harga *close* untuk memprediksi harga saham di masa mendatang serta memprediksi harga saham di masa mendatang berdasarkan data historis.

3.1.2 Data Understanding

1. Pengumpulan Data

Tahap ini melakukan pengumpulan data, data yang dikumpulkan pada tahap ini adalah pemahaman pada proses pemahaman bisnis, data yang dikumpulkan berupa data historis Indeks Harga Saham Gabungan (IHSG) dengan kode *JKSE* yang di dapatkan dari *yahoo finance* periode 2018-2023 dengan frekuensi harian dan data Covid-19 sebagai data tambahan periode 2020-2022 yang didapatkan dari *kaggle*.

Tabel 1. Sampel Dataset IHSG 2018-2023

Date	Open	High	Low	Close	Adj Close	Volume
10/01/2018	6.380.917.969	6.412.028.809	6.355.219.238	6.371.173.828	6.371.173.828	70066900.0
11/01/2018	6.375.030.762	6.386.338.867	6.344.040.039	6.386.338.867	6.386.338.867	117346700.0
12/01/2018	6.391.466.797	6.409.174.805	6.359.832.031	6.370.064.941	6.370.064.941	86340200.0

Pada tabel 1 merupakan sampel data dari dataset IHSG 2018-2023 dengan atribut *date*, *open*, *high*, *low*, *close*, *adj close* serta *volume*. Setiap kolom angka seperti direpresentasikan sebagai bilangan *real (float)*

karena mereka mengandung nilai desimal atau representasi numerik yang presisi dan datetime pada atribut *date*.


Tabel 2. Statistik Data

Statistik	Open	High	Low	Close	Adj Close	Volume
Count	1451.000000	1451.000000	1451.000000	1451.000000	1451.000000	1451.000000
Mean	6280.379782	6313.383090	6241.989968	6278.104249	6278.104249	136175487.00
Std	632.931858	629.464327	636.944611	633.080252	633.080252	69003747.52
Min	3937.632080	4123.562012	3911.716064	3937.632080	3937.632080	0.00
25%	6000.286621	6027.844482	5955.273194	5994.389649	5994.389649	79561949.50
50%	6323.811035	6342.686035	6289.452148	6320.004883	6320.004883	12936853.00
75%	6787.081543	6818.503907	6737.298584	6789.186035	6789.186035	180633047.00
Max	7317.895996	7377.495117	7278.198242	7318.016113	7318.016113	615071892.00

Dari analisis statistik di atas, tampak bahwa data saham menunjukkan *volatilitas* yang signifikan dalam harga dan *volume* perdagangan. *Fluktuasi* harga yang besar antara nilai minimum dan maksimum serta *deviasi* standar yang tinggi mencerminkan adanya ketidakpastian pasar dan pergerakan harga yang tidak stabil.


2. Differencing

Setelah menentukan atribut dataset, selanjutnya melakukan first differencing untuk menstasionerkan data agar tidak berfluktuatif, seperti gambar dibawah ini data mengalami flukatif sehingga diperlukan first differencing.




Gambar 3. Grafik Covid-19 Periode 2020-2022

Gambar diatas merupakan demo grafik dari *dataset* kasus baru pandemi covid-19 periode 2020-2022, terlihat jelas data diatas naik turun ber-*fluktuatif* dan tidak *stasioner*.




Gambar 4. Grafik IHSG Periode 2018-2023

Gambar diatas merupakan demo grafik dari *dataset* nilai saham dari 2018 sampai 2023, terlihat jelas data diatas naik turun ber-*fluktuatif* dan tidak *stasioner*.



Gambar 5. *Difference Covid-19*

Gambar diatas merupakan proses *first differencing* dengan menggunakan *google colab* menggunakan fungsi *diff()*, setelah di *first differencing* maka *dataset* di simpan dan di *filter* hingga diambil harga *close* dan *date*-nya saja.



Gambar 6. Grafik *First Different IHSG*

Gambar diatas merupakan visualisasi dari hasil *first different* dengan menggunakan perangkat *colab*, terlihat grafik gambar diatas sudah stasioner dan sudah siap untuk pemodelan data..

4. Missing Values

Setelah dilakukan differencing data, selanjutnya penulis melakukan pengecekan *missing values* pada dataset.

```
[12]
# 3. Memeriksa Missing Values
print("\nJumlah Missing Values per Kolom:\n", df.isnull().sum())


Jumlah Missing Values per Kolom:
Date          0
Open          23
High          23
Low           23
Close         23
Adj Close     23
Volume        23
dtype: int64
```

Gambar 7. Cek *Missing values*

Gambar diatas menunjukkan bahwa terdapat *missing values* pada setiap variabel yang ada dengan masing masing *missing values* berjumlah 23.

5. Outliers

Pada tahap ini, dilakukan pengecekan terhadap *outlier* yang terdapat pada dataset.



Gambar 8. Outliers IHSG

Berdasarkan hasil visualisasi *box plot* pada variabel *Close*, teridentifikasi adanya beberapa *outlier* di bagian bawah distribusi data.

3.1.3 Data Prepration

Tahapan ini dijalankan dengan *cleaning data*, membersihkan *outliers* yang bertujuan untuk membersihkan data dari *missing values* serta normalisasi data.

1. Cleaning data

Untuk membersihkan *missing values* diatas maka dilakukan mengisinya dengan nilai *median* menggunakan *colabotatory* dengan perintah *df.fillna*.

```
# 4. Menangani Missing Values
# Anda bisa mengisi missing values dengan mean, median, modus, atau menghapusnya
df.fillna(df.median(numeric_only=True), inplace=True)

print("\nJumlah Missing Values per Kolom:\n", df.isnull().sum())
```


```
Jumlah Missing Values per Kolom:
Date      0
Open      0
High      0
Low       0
Close     0
Adj Close 0
Volume    0
dtype: int64
```

Gambar 9. Cleaning Data

Gambar diatas merupakan proses pembersihan *missing values* pada *dataset* harga saham periode 2019-2023 dengan menggunakan *collaboratory*, terlihat bahwa jumlah *missing values* pada *dataset* sudah bersih.

2. Normalisasi Data

Pembersihan *outliers* dilakukan dengan metode *IQR* yang sesuai agar data yang digunakan dalam proses analisis tidak dipengaruhi oleh nilai-nilai ekstrem yang dapat mengganggu akurasi prediksi.



Gambar 10. Membersihkan Outliers IHSG

Setelah pembersihan *outliers* dilakukan, *dataset* yang digunakan menjadi lebih bersih dan hanya mencakup data yang merepresentasikan pola yang sesungguhnya.

3. *Subset Data*

Pemilihan *subset* sangat penting dilakukan untuk menganalisis data lebih lanjut dan mengurangi ukuran dataset dan fokus pada data yang *relevan*.

Tabel 3. Sampel Data Covid-19 Differencing

Date	new_cases_diff
02/03/2020	0.0
02/03/2020	0.0
02/03/2020	-1.0
03/03/2020	1.0
03/03/2020	-2.0

Tabel 2 menunjukkan sampel data *Covid-19* setelah dilakukan *differencing*, yaitu proses transformasi data yang digunakan untuk menghilangkan tren atau pola musiman.

Tabel 4. Sampel Data IHSG *Differencing*

Date	Close
10/01/2018	-19.702.150.000.002.800
11/01/2018	15.165.039.000.000.400
12/01/2018	-16.273.926.000.000.700

Terlihat dari gambar 4.4 bahwa sudah tidak ada *atribute* yang *value*, yang menandakan data tersebut sudah tidak ada lagi *missing values*.

3.1.4 *InModeling*

Model prediksi ini menggunakan metode *K-Fold Cross-Validation* dengan 3 dan 10 *fold* untuk menemukan parameter terbaik dari model ARIMA, yang dioptimalkan berdasarkan kinerja metrik seperti *RMSE*, *MAE*.

```
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np
import pandas as pd #Added import statement
```

Gambar 11. *Import Library*

Gambar 11 memperlihatkan langkah *import library* di *Google Colab*, yang menjadi tahap awal dalam analisis data atau pemodelan. Pada tahap ini, pustaka (*library*) yang diperlukan untuk pemrosesan data, analisis statistik, dan pengembangan model diimpor ke dalam *notebook*.


```
# Load dataset saham dan COVID-19
stock_data = pd.read_csv('/content/difference_data.csv', parse_dates=['Date']) #Added code from cell ipython-input-18-63ec7bb944ae
covid_data = pd.read_csv('/content/covid_19_indonesia_cleaned.csv', parse_dates=['Date']) #Added code from cell ipython-input-18-63ec7bb944ae

# Gabungkan dataset berdasarkan tanggal
merged_data = pd.merge(stock_data, covid_data, on='Date', how='inner') #Added code from cell ipython-input-18-63ec7bb944ae

# Menampilkan data setelah digabung
print(merged_data.head()) #Added code from cell ipython-input-18-63ec7bb944ae

# Memilih kolom yang relevan (misalnya, 'Close' untuk harga saham dan 'New Cases' untuk COVID-19)
data = merged_data[['Close', 'new_cases_diff']] #Added code from cell ipython-input-13-63ec7bb944ae

# Melakukan interpolasi untuk menangani missing values
data = data.interpolate() #Added code from cell ipython-input-13-63ec7bb944ae

# Menampilkan data yang sudah diproses
print(data.head()) #Added code from cell ipython-input-13-63ec7bb944ae

# Ambil kolom harga saham ('Close') untuk analisis
stock_prices = data['Close'].values

# Evaluasi ARIMA dengan cross-validation menggunakan rolling window
mse = rolling_window_cross_validation(stock_prices, order)
print(f'Mean Squared Error: {mse}')
```

Gambar 12. Load Dataset

Gambar 12. adalah kode untuk mempersiapkan data harga saham dan kasus Covid-19 untuk dianalisis menggunakan model ARIMA dengan metode *rolling window cross-validation*.

```
# Grid search untuk parameter terbaik
p_values = d_values = q_values = range(0, 3)
best_score, best_cfg = float("inf"), None
for p, d, q in itertools.product(p_values, d_values, q_values):
    try:
        mse, mae, mape = evaluate_arima_model(train, test, p, d, q)
        if mse < best_score:
            best_score, best_cfg = mse, (p, d, q)
            print('ARIMA%s MSE=%.3f' % ((p, d, q), mse))
    except Exception as e:
        print(f'Error for ARIMA({p},{d},{q}): {e}')
        continue
print('Best ARIMA%s MSE=%.3f' % (best_cfg, best_score))
```

Gambar 13. Grid Search

Gambar 13. adalah metode yang berguna untuk menentukan *parameter p, d, dan q* optimal dalam model ARIMA melalui proses *grid search*, yang menguji berbagai kombinasi nilai untuk menemukan model dengan kesalahan terkecil (MSE terendah).

```
def evaluate_arima_model(train, test, order):
    # Convert train and test to numeric type to avoid timestamp errors
    train = pd.to_numeric(train)
    test = pd.to_numeric(test)

    model = ARIMA(train, order=order)
    model_fit = model.fit()
    predictions = model_fit.forecast(steps=len(test))
    rmse = np.sqrt(mean_squared_error(test, predictions))
    mae = mean_absolute_error(test, predictions)

    test = test.reset_index(drop=True)
    predictions = predictions.reset_index(drop=True)

    return predictions, rmse, mae
```

Gambar 14. Model Prediksi Colabatory

Gambar tersebut menampilkan sebuah fungsi *Python* yang berfungsi untuk mengukur performa model ARIMA dengan menggunakan data train dan test. Fungsi ini dinamai *evaluate_arima_model* dan memiliki tiga parameter: *train*, *test*, dan *order* (yang merepresentasikan parameter ARIMA).

```
def cross_validate_arima(data, folds, order):
    tscv = TimeSeriesSplit(n_splits=folds)
    rmse, maes, mape = [], [], []
    actuals, predictions = [], []


    for train_index, test_index in tscv.split(data):
        train, test = data.iloc[train_index], data.iloc[test_index]
        # Ensure only the 'Close' column is used which contains numeric data
        pred, rmse, mae, mape = evaluate_arima_model(train['Close'], test['Close'], order)
        actuals.append(test['Close'].values)
        predictions.append(pred)
        rmse.append(rmse)
        maes.append(maes)
        mape.append(mape)

    return actuals, predictions, rmse, maes

# Example usage
order = (2,1,2) # ARIMA order (p,d,q) - can be optimized
actuals_3fold, preds_3fold, rmse_3fold, maes_3fold = cross_validate_arima(data, 3, order)
actuals_10fold, preds_10fold, rmse_10fold, maes_10fold = cross_validate_arima(data, 10, order)
```

Gambar 15. K-Fold Cross-Validation

Gambar 15 menunjukkan implementasi *K-Fold Cross-Validation* yang digunakan untuk mengevaluasi performa model ARIMA dalam memprediksi data *time series*.



```

print("3-fold Cross-validation Results:")
print(f"Average RMSE: {np.mean(rmses_3fold)}")
print(f"Average MAE: {np.mean(maes_3fold)}")

print("\n10-fold Cross-validation Results:")
print(f"Average RMSE: {np.mean(rmses_10fold)}")
print(f"Average MAE: {np.mean(maes_10fold)}")

```

Gambar 16. Test Metrik

Kode diatas mengevaluasi model ARIMA berdasarkan tiga metrik performa utama (*MAE*, *RMSE*, *MAPE*) setelah model dilatih dan diuji pada data harga saham.

3.1.5 Evaluation

Pada tahap evaluasi, performa model akan dianalisis menggunakan dua metrik utama, yaitu *Root Mean Squared Error (RMSE)* dan *Mean Absolute Error (MAE)*.

Tabel 5. K-Fold 3

Parameter	RMSE	MAE
(2, 1, 2)	1.34	9.76
(2, 1, 2)	6.38	4.56
(2, 1, 2)	5.39	3.68

Tabel 5 menampilkan hasil evaluasi model ARIMA dengan *parameter* (2, 1, 2) menggunakan teknik *K-Fold Cross-Validation* dengan 3 fold. Pada tabel tersebut, metrik evaluasi yang digunakan adalah *Root Mean Squared Error (RMSE)* dan *Mean Absolute Error (MAE)*. Hasil dari tiga fold menunjukkan variasi nilai *RMSE* dan *MAE* untuk setiap subset data uji pada *fold* pertama, *RMSE* tercatat sebesar 1.34 dan *MAE* sebesar 9.76, pada *fold* kedua, *RMSE* meningkat menjadi 6.38 dan *MAE* sebesar 4.56, dan pada *fold* ketiga, *RMSE* sedikit menurun menjadi 5.39 dengan *MAE* sebesar 3.68.


Tabel 6. K-Fold 10

Parameter	RMSE	MAE
(2, 1, 2)	4.63	3.41
(2, 1, 2)	2.56	1.84
(2, 1, 2)	1.75	1.67
(2, 1, 2)	2.85	2.17
(2, 1, 2)	6.97	5.42
(2, 1, 2)	1.58	1.22
(2, 1, 2)	3.67	1.92
(2, 1, 2)	3.28	2.29
(2, 1, 2)	3.24	2.20
(2, 1, 2)	1.43	1.13

Tabel 6 menampilkan hasil evaluasi model ARIMA dengan *parameter* (2, 1, 2) menggunakan *K-Fold Cross-Validation* dengan 10 fold. Pada tabel ini, performa model dievaluasi berdasarkan dua metrik, yaitu *Root Mean Squared Error (RMSE)* dan *Mean Absolute Error (MAE)*, untuk setiap *fold*. Berikut adalah rangkuman hasil evaluasi, nilai *RMSE* berkisar antara 1.43 hingga 6.97, menunjukkan adanya variasi performa model di setiap *fold*. *Fold* dengan performa terbaik ditandai dengan nilai *RMSE* sebesar 1.43 pada *fold* ke-10.

3.1.6 Deployment

Pada tahap *deployment*, dilakukan visualisasi data guna mempermudah *interpretasi* hasil prediksi yang telah dihasilkan oleh model.



Gambar 17. *Forecasting*

Gambar 3.17 menampilkan hasil proses *forecasting* atau peramalan menggunakan model ARIMA dengan data yang mencakup pengaruh COVID-19. Pada grafik tersebut, hasil peramalan model diperbandingkan dengan data historis dan aktual untuk mengevaluasi akurasi prediksi model.

Komponen yang ditampilkan pada grafik ini meliputi:

1. Data pelatihan (*Train*): Menunjukkan data historis yang digunakan untuk melatih model, di mana pergerakan harga yang signifikan dapat diamati, terutama di masa awal pandemi.
2. Data aktual (*Actual*): Merupakan data harga atau nilai yang sebenarnya terjadi setelah periode pelatihan, digunakan untuk menguji performa model dalam memprediksi nilai di masa depan.
3. Data prediksi (*Predicted*): Hasil prediksi dari model ARIMA untuk periode data uji. Model mencoba memproyeksikan nilai di masa mendatang berdasarkan pola historis.
4. Dari visualisasi ini, dapat diamati bahwa model ARIMA memberikan prediksi yang cukup akurat dengan sebagian besar prediksi mendekati data aktual. Perbedaan kecil antara nilai aktual dan prediksi mungkin mencerminkan dampak *fluktuasi* pasar atau kondisi ekonomi yang sulit diprediksi, seperti pandemi COVID-19.

4. KESIMPULAN

Berdasarkan tujuan penelitian yang telah direncanakan, kesimpulan yang dapat diambil adalah bahwa penelitian ini berhasil menerapkan metode ARIMA untuk mengamati pergerakan nilai saham IHSG pada harga penutupan menggunakan perangkat lunak *Colabatory*. Model ARIMA (2, 1, 2) yang diterapkan telah diuji dan menunjukkan hasil yang memadai dalam meramalkan nilai saham. Kinerja model ARIMA dievaluasi menggunakan metrik *RMSE* dan *MAE*, dengan hasil evaluasi menunjukkan nilai *RMSE* sebesar 1.43 dan *MAE* 1.13, yang mengindikasikan bahwa model ini memiliki tingkat keakuratan yang dapat diandalkan dalam memprediksi pergerakan harga saham IHSG. Dari temuan penelitian ini, beberapa rekomendasi untuk pengembangan dan peningkatan studi selanjutnya adalah sebagai berikut: pertama, disarankan untuk mencoba model prediksi lain seperti *Long Short-Term Memory* (LSTM) atau *Support Vector Regression* (SVR) untuk membandingkan hasil dan menemukan model yang paling optimal dalam memprediksi harga saham. Kedua, penelitian ini menggunakan data historis IHSG, sehingga disarankan agar penelitian berikutnya memasukkan faktor eksternal lainnya, seperti kondisi ekonomi *makro*, peristiwa politik, dan faktor global yang mungkin memengaruhi pergerakan harga saham IHSG. Ketiga, hasil penelitian ini dapat dikembangkan menjadi sistem informasi yang dapat digunakan oleh investor untuk membantu pengambilan keputusan investasi dengan menampilkan prediksi harga saham secara *real-time* dan memberikan analisis tren yang mendalam. Dengan menerapkan saran-saran di atas, diharapkan prediksi harga saham menjadi lebih akurat dan bermanfaat bagi para *investor* serta peneliti di bidang pasar modal.

REFERENSI

- [1] A. Azzam *et al.*, “Analisis Peran Kewirausahaan Dalam Mendorong Pertumbuhan Ekonomi,” vol. 2, no. 6, pp. 656–666, 2024, doi: <https://doi.org/10.572349/neraca.v2i6.1873>.
- [2] H. E. B. A. Cania Ferennita, “Pengaruh Literasi Keuangan, Advocate Recommendation dan Overconfidence terhadap Pengambilan Keputusan Investasi Saham Oleh Investor Muda di Kota Semarang (Studi Pada Investor Muda yang Terdaftar di Phintraco Sekuritas Cabang Semarang),” *Agustus 2022 Journal of Accounting and Finance*, vol. 1, no. 1, doi: <http://dx.doi.org/10.31942/jafin.v1i1.7009>.
- [3] A. Arfan and L. ETP, “Perbandingan Algoritma Long Short-Term Memory dengan SVR Pada Prediksi Harga Saham di Indonesia,” *PETIR*, vol. 13, no. 1, pp. 33–43, Mar. 2020, doi: [10.33322/petir.v13i1.858](https://doi.org/10.33322/petir.v13i1.858).
- [4] Narisa Fakhriani Saputri and Zulfa Irawati, “Analisis Pengaruh Bi Rate, Nilai Tukar Rupiah, Indeks Dow Jones, Indeks Nikkei 225 Terhadap Indeks Harga Saham Gabungan (IHSG) Di Bursa Efek Indonesia,” *Jurnal Ekuilnomi*, vol. 5, no. 2, pp. 361–373, Nov. 2023, doi: <https://doi.org/10.36985/xn60as56>.
- [5] M. S. S. H. Surya Darmawan, “Analisis pengaruh makroekonomi, indeks saham global, harga emas dunia dan harga minyak dunia terhadap Indeks Harga Saham Gabungan (IHSG),” doi: <http://dx.doi.org/10.26623/jreb.v15i2.4381>.
- [6] A. Basit, “Pengaruh Harga Emas Dan Minyak Dunia Terhadap Indeks Harga Saham Gabungan (IHSG) Periode 2016-2019,” *REVENUE: Jurnal Manajemen Bisnis Islam*, vol. 1, no. 2, pp. 73–82, Aug. 2020, doi: [10.24042/revenue.v1i2.6073](https://doi.org/10.24042/revenue.v1i2.6073).
- [7] Kasei.co.id, “Didominasi Milenial dan Gen Z, Jumlah Investor Saham Tembus 4 Juta,” 2022. Accessed: Jan. 18, 2024. [Online]. Available: https://www.ksei.co.id/files/uploads/press_releases/press_file/id-id/208_berita_pers_didominasi_milenial_dan_gen_z_jumlah_investor_saham_tembus_4_juta_20220725182203.pdf
- [8] Henny Saraswati, “Dampak Pandemi Covid-19 Terhadap Pasar Saham Di Indonesia,” Desember, 2020, doi: <https://doi.org/10.26533/jad.v3i2.696>.
- [9] S. P. Fauzani and D. Rahmi, “Penerapan Metode ARIMA Dalam Peramalan Harga Produksi Karet di Provinsi Riau,” *Jurnal Teknologi dan Manajemen Industri Terapan (JTMIT)*, vol. 2, no. 4, pp. 269–277, 2023.
- [10] W. R. U. Fadilah, D. Agfiannisa, and Y. Azhar, “Analisis Prediksi Harga Saham PT. Telekomunikasi Indonesia Menggunakan Metode Support Vector Machine,” *Fountain of Informatics Journal*, vol. 5, no. 2, p. 45, Sep. 2020, doi: [10.21111/fij.v5i2.4449](https://doi.org/10.21111/fij.v5i2.4449).
- [11] M. R. Pribadi, E. Maria, S. Trihadaru, Y. J. Prasetyo, and S. Wijono, “Implementasi Algoritma Neural Network Dengan Optimisasi Hyperparameter Untuk Prediksi Harga Saham,” *Julyxxxx*, vol. x, No.x, pp. 1–5, 2022, doi: <https://doi.org/10.35957/jatisi.v9i4.3658>.
- [12] R. Dona Ariyatma and S. Fahmi, “Data Mining Menggunakan Multiple Regression untuk Prediksi Harga Saham Netflix,” *Jurnal SAINTEKOM*, vol. 13, no. 2, pp. 184–192, Sep. 2023, doi: [10.33020/saintekom.v13i2.419](https://doi.org/10.33020/saintekom.v13i2.419).
- [13] R. Bagaskara Radite Putra, “Multivariate Time Series Forecasting pada Penjualan Barang Retail dengan Recurrent Neural Network,” vol. 7, no. 1, p. 2022, 2022, doi: <https://doi.org/10.35314/isi.v7i1.2398>.
- [14] Pete Chapman, *CRISP-DM 1.0 Step-by-step data mining guide*. DaimlerChrysler, 2000. Accessed: Sep. 22, 2024. [Online]. Available: <https://api.semanticscholar.org/CorpusID:59777418>
- [15] T. Nafsiah Muthmainnah, A. Voutama, and Andri Hendriadi, “Klasterisasi Penerima Bantuan Langsung Tunai (Blt) Dana Desa Menggunakan Algoritma K-Means,” 2024. doi: <https://doi.org/10.36040/jati.v8i3.9848>.
- [16] J. Brzozowska, J. Pizoń, G. Baytikenova, A. Gola, A. Zakimova, and K. Piotrowska, “Data Engineering In Crisp-Dm Process Production Data – Case Study,” *Applied Computer Science*, vol. 19, no. 3, pp. 83–95, 2023, doi: [10.35784/acs-2023-26](https://doi.org/10.35784/acs-2023-26).
- [17] A. Pramudiansyah and H. Munte, “Segmentasi Pelanggan Menggunakan Algoritma K-Means Berdasarkan Model Recency Frequency Monetary,” vol. 7, no. 2, 2021, doi: <https://doi.org/10.35329/jiik.v7i2.201>.
- [18] A. Priyatna, “RESOLUSI: Rekayasa Teknik Informatika dan Informasi Evaluasi Pemahaman Siswa Dalam Proses Belajar Secara Online dengan Menggunakan Algoritma C5.0,” *Media Online*, vol. 4, no. 3, p. 309, 2024, doi: <https://doi.org/10.30865/resolusi.v4i3.1640>.

- [19] Y. Christian and K. O. Y. R. Qi, “Penerapan K-Means pada Segmentasi Pasar untuk Riset Pemasaran pada Startup Early Stage dengan Menggunakan CRISP-DM,” *JURIKOM (Jurnal Riset Komputer)*, vol. 9, no. 4, p. 966, Aug. 2022, doi: 10.30865/jurikom.v9i4.4486.
- [20] B. Jange, “Prediksi Indeks Harga Saham Gabungan (Ihsg) Menggunakan Prophet,” *Jotika J. Manag. Entrep.*, vol. 1, no. 2, pp. 53–59, Feb. 2022, doi: 10.56445/jme.v1i2.18.
- [21] A. Riyandi, A. Aripin, I. N. Ardiansyah, R. Dany, and Y. Yusrizal, “Analisis Data Mining untuk Prediksi Harga Saham: Perbandingan Metode Regresi Linier dan Pola Historis,” *J. Teknol. Sist. Inf.*, vol. 4, no. 2, pp. 278–288, Sep. 2023, doi: 10.35957/jtsi.v4i2.5158.
- [22] N. C. Sastya and I. Nugraha, “Penerapan Metode CRISP-DM dalam Menganalisis Data untuk Menentukan Customer Behavior di MeatSolution,” *UNISTEK*, vol. 10, no. 2, pp. 103–115, Oct. 2023, doi: 10.33592/unistek.v10i2.3079.