

Prediksi Saham Bank Central Asia Menggunakan Temporal Convolutional Network

Nanda Darma Wirawan, Eddy Muntina Dharma, Made Adi Paramartha Putra

Universitas Primakara, Indonesia

Email: halo.nanda.darma@gmail.com, eddy@primakara.ac.id, adi@primakara.ac.id

Abstrak

Pasar saham merupakan salah satu instrumen investasi yang memiliki peran penting dalam pertumbuhan ekonomi dan pengembangan pasar keuangan. Peningkatan jumlah investor di Indonesia mendorong kebutuhan akan metode analisis yang lebih akurat untuk memprediksi pergerakan harga saham. Saham PT Bank Central Asia Tbk (BBCA) sebagai salah satu emiten dengan kapitalisasi pasar terbesar di Bursa Efek Indonesia menjadi objek penting dalam analisis prediksi harga saham. Namun, karakteristik data pasar saham yang bersifat non-linear, dinamis, dan dipengaruhi berbagai faktor membuat proses prediksi menjadi kompleks. Oleh karena itu, penelitian ini bertujuan untuk mengembangkan model prediksi harga tertinggi (High_next) dan harga terendah (Low_next) saham BBCA menggunakan pendekatan Temporal Convolutional Network (TCN) dengan memanfaatkan kombinasi indikator teknikal dan indikator makroekonomi. Penelitian ini menggunakan pendekatan kuantitatif eksperimental dengan framework CRISP-DM yang meliputi tahapan business understanding, data understanding, data preparation, modeling, evaluation, dan deployment. Data yang digunakan merupakan data historis bulanan periode Januari 2009 hingga Agustus 2025 yang terdiri dari indikator teknikal saham serta indikator makro seperti IHSG, nilai tukar USD/IDR, dan suku bunga Bank Indonesia. Hasil penelitian menunjukkan bahwa model TCN mampu menghasilkan prediksi yang akurat dengan kinerja terbaik pada skenario TECH untuk prediksi High_next dan skenario ALL untuk prediksi Low_next, serta secara konsisten mengungguli model baseline linear berdasarkan metrik MAE, RMSE, sMAPE, dan MASE. Dengan demikian, model TCN terbukti efektif dalam memodelkan deret waktu keuangan dan dapat digunakan sebagai alat bantu analisis bagi investor dalam pengambilan keputusan investasi berbasis data.

Kata kunci: TCN; BBCA; High_next; Low_next; indikator teknis; indikator makro/fundamental; MAE; RMSE; sMAPE; MASE.

Abstract

The stock market plays an important role in supporting economic growth and financial market development. The increasing number of investors in Indonesia has intensified the need for more accurate analytical methods to predict stock price movements. Shares of PT Bank Central Asia Tbk (BBCA), as one of the companies with the largest market capitalization on the Indonesia Stock Exchange, represent an important object of stock price prediction analysis. However, the characteristics of stock market data, which are nonlinear, dynamic, and influenced by various internal and external factors, make prediction a complex task. Therefore, this study aims to develop a prediction model for the next-period highest price (High_next) and lowest price (Low_next) of BBCA shares using the Temporal Convolutional Network (TCN) approach by integrating technical indicators and macroeconomic indicators. This research employs a quantitative experimental approach using the CRISP-DM framework, which includes business understanding, data understanding, data preparation, modeling, evaluation, and deployment stages. The dataset consists of monthly historical data from January 2009 to August 2025, incorporating technical indicators along with macroeconomic variables such as the Composite Stock Price Index (IHSG), USD/IDR exchange rate, and Bank Indonesia policy rate. The results show that the TCN model produces accurate predictions, with the TECH scenario performing best for High_next prediction and the ALL scenario showing the best performance for Low_next prediction. Furthermore, the TCN model consistently outperforms baseline linear models based on MAE, RMSE, sMAPE, and MASE metrics. These findings indicate that the TCN model is effective for financial time-series forecasting and can serve as a data-driven decision-support tool for investors.

Keywords: *TCN; BBCA; High_next; Low_next; technical indicators; macro/fundamental indicators; MAE; RMSE; sMAPE; MASE.*

PENDAHULUAN

Pasar saham memainkan peran penting dalam mendukung pertumbuhan ekonomi suatu negara (Setiawan et al., 2020). Sebagai salah satu instrumen investasi utama, saham tidak hanya menjadi sarana penggalangan dana bagi perusahaan tetapi juga menawarkan peluang keuntungan yang signifikan bagi investor (Aisya, Sarjan et al., 2025).

Di Indonesia, minat terhadap investasi saham terus meningkat, tercermin dari data Bursa Efek Indonesia (BEI) Agustus 2025, mencatat jumlah investor saham mencapai 18 juta lebih single investor identification (SID), meningkat lebih dari 3 juta investor baru atau 21% secara year to date dibandingkan dengan akhir tahun 2024 yang berjumlah 14,87 juta investor (idx.co.id, 2025). Peningkatan ini mencerminkan dinamika pasar modal yang semakin berkembang, sehingga kebutuhan akan analisis yang akurat untuk mendukung pengambilan keputusan investasi menjadi semakin penting.

Di tengah tingginya minat tersebut, PT Bank Central Asia Tbk (BBCA) menempati posisi khusus karena dipersepsikan sebagai emiten perbankan unggulan dengan kapitalisasi pasar yang sangat besar di Bursa Efek Indonesia; pada Oktober 2025 kapitalisasi pasarnya dilaporkan sekitar Rp1.050,71 triliun dan menempatkan di jajaran teratas emiten berkapitalisasi besar di Bursa Efek Indonesia (Google Finance, 2025). Sebagai saham berkapitalisasi raksasa dan sangat likuid, pergerakan harga BBCA sering dijadikan acuan sentimen sektor perbankan serta indikator kepercayaan investor terhadap stabilitas pasar saham Indonesia (Alamsyahbana et al., 2023). Oleh karena itu, kemampuan memprediksi kisaran harga tertinggi (high) dan harga terendah (low) saham BBCA untuk periode berikutnya bernilai strategis, baik untuk manajemen risiko portofolio maupun untuk penentuan timing masuk/keluar posisi oleh investor ritel dan institusional.

Namun, memprediksi harga saham merupakan tugas yang kompleks. Data harga saham bersifat deret waktu (time series) yang sering kali menunjukkan pola non-linear, berubah cepat, serta dipengaruhi banyak faktor eksternal, sehingga sulit diprediksi secara konsisten dengan pendekatan klasik berbasis asumsi linear seperti ARIMA atau GARCH (Barua et al., 2024; Liu et al., 2025). Pendekatan deep learning muncul sebagai alternatif karena mampu mempelajari pola temporal yang rumit. Model rekuren seperti Long Short-Term Memory (LSTM) dirancang untuk menyimpan ketergantungan historis, tetapi model rekuren tetap menghadapi kendala teknis seperti vanishing gradient ketika diminta memproses konteks historis yang panjang (Bai et al., 2018).

Temporal Convolutional Network (TCN) ditawarkan sebagai arsitektur yang lebih stabil untuk pemodelan deret waktu jangka panjang karena menggunakan konvolusi kausal bertingkat (dilated causal convolutions) sehingga mampu menangkap dependensi jangka panjang tanpa harus “mengingat” secara berulang seperti LSTM (Bai et al., 2018). Evaluasi empiris menunjukkan bahwa TCN tidak hanya mampu menandingi, tetapi juga mengungguli LSTM pada berbagai tugas pemodelan sekuens, sambil mempertahankan memori efektif yang lebih panjang dan stabil (Bai et al., 2018).

Penelitian terapan pada data harga komoditas finansial jangka panjang juga melaporkan bahwa TCN murni mampu memprediksi harga secara lebih akurat (RMSE dan MAE lebih rendah) dibandingkan model-model populer lain seperti ARIMA, CNN, maupun LSTM, menegaskan bahwa TCN relevan untuk forecasting deret waktu bernuansa ekonomi/keuangan (Fajou, 2021a).

Studi lanjutan di ranah pasar saham menyoroti bahwa pendekatan berbasis TCN efektif dalam menangkap pola volatilitas harga saham dan dinamika non-linear pasar, sehingga layak dipertimbangkan sebagai model utama untuk prediksi pergerakan harga saham, bukan sekadar model pembanding (Liu et al., 2025).

Berdasarkan landasan tersebut, penelitian ini memfokuskan diri pada saham BBCA dan membangun model prediksi berbasis TCN menggunakan data historis bulanan sejak Januari 2009 hingga Agustus 2025. Dataset yang digunakan menggabungkan dua jenis informasi: (1) indikator teknikal saham (seperti Moving Average, Bollinger Bands, indikator momentum) yang merefleksikan perilaku harga internal saham BBCA; dan (2) indikator fundamental/makro (seperti IHSG sebagai sentimen pasar domestik, nilai tukar USD/IDR, serta suku bunga kebijakan Bank Indonesia sebagai sinyal kondisi moneter) yang merefleksikan tekanan eksternal terhadap pergerakan harga bank besar (Setiawan et al., 2020).

Sejumlah penelitian terdahulu telah berupaya mengembangkan model prediksi harga saham menggunakan berbagai pendekatan statistik maupun machine learning. Metode tradisional seperti Autoregressive Integrated Moving Average (ARIMA) dan Generalized Autoregressive Conditional Heteroskedasticity (GARCH) banyak digunakan untuk menganalisis data deret waktu keuangan, namun metode tersebut memiliki keterbatasan dalam menangkap pola non-linear dan kompleksitas dinamika pasar saham. Seiring berkembangnya teknologi komputasi, pendekatan berbasis machine learning dan deep learning mulai banyak digunakan untuk meningkatkan akurasi prediksi harga saham. Penelitian (Rouf et al., 2021) menunjukkan bahwa algoritma machine learning mampu meningkatkan performa prediksi dibandingkan metode statistik klasik. Selain itu, penelitian (Wathani et al., 2023) menggunakan Long Short-Term Memory (LSTM) untuk memprediksi tren harga saham BBCA dan menunjukkan bahwa model deep learning dapat menangkap pola temporal yang lebih kompleks dibandingkan metode konvensional.

Meskipun demikian, model berbasis recurrent neural network seperti LSTM masih menghadapi sejumlah kendala teknis, terutama terkait permasalahan vanishing gradient ketika memproses rangkaian data historis yang panjang. Kondisi ini dapat mengurangi kemampuan model dalam menangkap dependensi jangka panjang pada data deret waktu finansial yang kompleks. Oleh karena itu, beberapa penelitian terbaru mulai mengembangkan arsitektur alternatif yang lebih stabil untuk pemodelan time series, salah satunya adalah Temporal Convolutional Network (TCN). (Bai et al., 2018) menunjukkan bahwa TCN memiliki kemampuan memori yang lebih panjang serta stabilitas pelatihan yang lebih baik dibandingkan model rekuren tradisional. Penelitian lain oleh (Liu et al., 2025) juga menunjukkan bahwa TCN efektif dalam menangkap pola volatilitas dan dinamika non-linear pada pasar saham sehingga berpotensi menghasilkan prediksi yang lebih akurat.

Meskipun berbagai penelitian telah mengkaji penggunaan deep learning untuk prediksi harga saham, masih terdapat kesenjangan penelitian yang perlu diperhatikan. Sebagian besar penelitian sebelumnya hanya memanfaatkan satu jenis fitur, seperti indikator teknikal atau data

historis harga saham saja, tanpa mengombinasikan faktor makroekonomi yang dapat memengaruhi dinamika pasar secara lebih luas. Selain itu, penelitian yang secara khusus memprediksi rentang harga saham berupa harga tertinggi (high) dan harga terendah (low) pada periode berikutnya masih relatif terbatas, terutama pada konteks pasar saham Indonesia. Padahal, informasi mengenai rentang harga tersebut memiliki nilai strategis bagi investor dalam menentukan strategi manajemen risiko dan waktu transaksi investasi.


Berdasarkan kesenjangan tersebut, penelitian ini menjadi penting untuk dilakukan karena berupaya mengintegrasikan berbagai sumber informasi yang berpotensi memengaruhi pergerakan harga saham. Penelitian ini tidak hanya memanfaatkan indikator teknikal yang merepresentasikan perilaku internal harga saham, tetapi juga memasukkan indikator makroekonomi seperti Indeks Harga Saham Gabungan (IHSG), nilai tukar USD/IDR, serta suku bunga kebijakan Bank Indonesia yang mencerminkan kondisi ekonomi makro dan sentimen pasar. Dengan mengombinasikan kedua jenis indikator tersebut, diharapkan model prediksi yang dihasilkan dapat menangkap dinamika pasar secara lebih komprehensif dan memberikan hasil prediksi yang lebih akurat.

Kebaruan (novelty) penelitian ini terletak pada penerapan arsitektur Temporal Convolutional Network untuk memprediksi harga tertinggi dan harga terendah saham BBKA dalam horizon waktu bulanan dengan memanfaatkan kombinasi indikator teknikal dan indikator makroekonomi. Selain itu, penelitian ini juga mengintegrasikan pendekatan evaluasi prediksi yang komprehensif menggunakan beberapa metrik kesalahan seperti Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Symmetric Mean Absolute Percentage Error (sMAPE), dan Mean Absolute Scaled Error (MASE) untuk menilai performa model secara lebih objektif. Pendekatan ini memberikan kontribusi metodologis dalam pengembangan model prediksi harga saham berbasis deep learning pada data deret waktu finansial.

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk mengembangkan model prediksi harga tertinggi dan harga terendah saham PT Bank Central Asia Tbk menggunakan pendekatan Temporal Convolutional Network dengan memanfaatkan kombinasi indikator teknikal dan indikator makroekonomi. Hasil penelitian ini diharapkan dapat memberikan manfaat secara akademis maupun praktis. Secara akademis, penelitian ini dapat memperkaya literatur mengenai penerapan deep learning dalam analisis pasar keuangan, khususnya pada konteks pasar modal Indonesia. Secara praktis, model yang dihasilkan dapat menjadi alat bantu analisis bagi investor, analis pasar modal, maupun pengambil keputusan dalam memahami dinamika pergerakan harga saham serta menyusun strategi investasi yang lebih terukur dan berbasis data.

METODE PENELITIAN


Penelitian ini menggunakan pendekatan kuantitatif eksperimental untuk mengevaluasi performa model Temporal Convolutional Network (TCN) dalam memprediksi harga tertinggi dan terendah saham Bank Central Asia (BCA). Pendekatan ini memungkinkan pengujian berbagai konfigurasi model, termasuk kombinasi indikator teknikal dan fundamental serta variasi parameter, guna menentukan konfigurasi terbaik dengan akurasi yang tinggi. Proses validasi dilakukan secara sistematis dengan membagi data menjadi subset pelatihan dan pengujian untuk memastikan hasil yang andal.



Gambar 1 Alur CRISP-DM

Framework CRISP-DM (Cross-Industry Standard Process for Data Mining) digunakan sebagai panduan utama dalam pembuatan model karena menawarkan kerangka kerja sistematis yang berbasis data historis. Framework ini mencakup enam tahapan utama: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Pendekatan ini memastikan penelitian dilakukan secara terstruktur, mulai dari pemahaman kebutuhan analisis hingga evaluasi performa model, untuk menghasilkan model prediktif yang akurat, dapat diinterpretasikan, dan mendukung pengambilan keputusan investasi secara informatif. Penjelasan lebih rinci mengenai penerapan framework CRISP-DM dan setiap tahapan penelitian akan dijelaskan pada sub-bab 2 Alur Penelitian.

Alur Penelitian



Gambar 1 Alur Penelitian

HASIL DAN PEMBAHASAN


Bab ini menyajikan hasil dan pembahasan dari penerapan rancangan pada Bab III untuk memprediksi harga tertinggi bulanan (High_next) dan harga terendah bulanan (Low_next) saham BBKA dengan horizon satu bulan ke depan. Seluruh eksperimen dijalankan pada tiga skenario fitur ALL (gabungan indikator teknikal dan makro/ fundamental), TECH (teknikal saja), dan FUND (makro/ fundamental saja) agar terlihat kontribusi masing-masing kelompok informasi terhadap kinerja model. Output utama yang dilaporkan berupa point forecasts (prediksi titik) serta interval ketidakpastian konformal pada tingkat L90 dan L95, sehingga selain estimasi nilai, tersedia pula rentang keyakinan (proyeksi harga) yang dapat dipakai untuk pengambilan keputusan. Hasil disusun secara ringkas mengikuti alur CRISP-DM: ringkasan data dan praproses yang relevan, pemodelan TCN, evaluasi akurasi (MAE, RMSE, sMAPE, MASE) dan kualitas interval (coverage, AIW), diikuti interpretasi temuan per skenario dan implikasinya. Dengan demikian, Bab IV berfungsi sebagai jembatan dari metodologi ke bukti kinerja model di data validasi dan uji.

Arsitektur Model TCN (RQ 1)

Pada bagian ini menguraikan perancangan dan penerapan Temporal Convolutional Network (TCN) untuk memprediksi harga tertinggi bulanan (High_next) dan harga terendah bulanan (Low_next) saham BBCA satu bulan ke depan. Fokus mencakup: representasi data menjadi window 12 bulan, pembagian tiga skenario fitur (ALL/TECH/FUND), arsitektur TCN dengan tiga blok dilated causal Conv1d, dua output heads (High/Low), konfigurasi pelatihan, serta penataan artefak yang relevan untuk reproducibility.

Data Integrity

Bagian ini mendeskripsikan apa yang benar-benar dieksekusi sebelum modeling, berfokus pada pemeriksaan konsistensi dataset bulanan per skenario (ALL/TECH/ FUND). Seluruh cek dilakukan pada time index bulanan yang sudah end-of-month aligned dan dilaporkan sebagai artifact untuk auditability.




Gambar 3 Alur Data Integrity

Tahap ini diawali dengan pemeriksaan time index agar bersifat monoton dan hanya memuat satu baris per bulan tanpa duplikasi maupun celah; setiap anomali kalender seperti bulan ganda atau bulan yang hilang tidak langsung diperbaiki, melainkan diberi flag dan dicatat dalam ringkasan untuk penanganan terkontrol pada tahap berikutnya. Selanjutnya dilakukan verifikasi kelengkapan kolom dan tipe data terhadap feature list final per skenario, di mana seluruh kolom wajib—meliputi OHLC BBCA, fitur teknikal, serta fitur makro/fundamental sesuai skenario—harus tersedia, bertipe numerik, dan bebas dari nilai tak hingga, kemudian diterapkan sanity-check OHLC dengan aturan $\text{High} \geq \max(\text{Open}, \text{Close}, \text{Low})$, $\text{Low} \leq \min(\text{Open}, \text{Close}, \text{High})$, serta $\text{High} \geq \text{Low}$ pada setiap bulan; setiap pelanggaran aturan bisnis tidak dimodifikasi, hanya ditandai sebagai temuan struktural. Setelah itu, missing values diaudit per kolom dengan pemberian flag khusus untuk kasus late-release pada seri makro (misalnya rilis kebijakan di pertengahan bulan) guna mencegah bias look-ahead, disertai pemindaian outlier indikatif berbasis kuantil per kolom tanpa mengubah nilai, serta inventarisasi potensi duplikasi baris dan kolom redundan, sementara seluruh perubahan ditunda hingga tahap preprocessing.

Seluruh temuan kemudian diserialisasi ke dalam artifact agar dapat direplikasi dan ditinjau ulang, berupa laporan ringkas integritas per skenario pada `artifacts/quality/integrity_report_{scenario}.json` serta rekap missing dan late-release pada `artifacts/quality/missing_summary_{scenario}.csv`, dengan kriteria kelulusan tahap ini adalah tidak adanya pelanggaran kritis yang menghambat proses windowing dan scaling, serta seluruh temuan minor terdokumentasi secara lengkap untuk ditangani pada tahap preprocessing.

Blueprint Arsitektur Model TCN

Subbab ini mengunci spesifikasi arsitektur, kontrak bentuk tensor, serta artefak konfigurasi agar pipeline deterministik dan reproducible. Ilustrasi proses ditampilkan pada Gambar 4 (flow), sedangkan detail jaringan pada Gambar 4.1.7b (arsitektur lengkap: dilated causal conv, residual block zoom, dan dual heads).



Gambar 4 Alur *Blueprint* Arsitektur TCN


Untuk menjawab RQ2 pada aspek point forecast, evaluasi dilakukan pada data TEST sebagai hold-out terakhir dengan skema time-based split tanpa shuffle untuk dua target, yaitu High_next dan Low_next, menggunakan metrik MAE, RMSE, sMAPE, dan MASE yang dilaporkan dalam skala Rupiah untuk MAE/RMSE serta dalam persentase untuk sMAPE. Data VALIDATION (VAL) hanya dimanfaatkan untuk pemilihan best checkpoint, dengan ringkasan best epoch pada tiap skenario disajikan melalui kurva train_loss versus val_loss serta learning-rate schedule. Hasil utama pada data TEST menunjukkan bahwa secara umum skenario TECH merupakan yang terbaik untuk memprediksi High_next, sedangkan skenario ALL memberikan kinerja terbaik untuk Low_next, sementara skenario FUND yang hanya menggunakan indikator fundamental secara konsisten menghasilkan tingkat kesalahan tertinggi pada kedua target.

Tabel 1 Akurasi *Test Point Forecast* dan Target

Scenario	Target	MAE	RMSE	sMAPE	MASE
ALL	High	370.6509399	468.3822021	0.03818685189	2.602030
ALL	Low	680.6582031	746.5829468	0.07780002058	4.323099
FUND	High	1633.335083	1778.204102	0.183392942	11.46628
FUND	Low	1494.750854	1669.653198	0.1807470769	9.493688
TECH	High	364.8619385	447.5984497	0.03834193572	2.561390
TECH	Low	1360.015381	1396.943359	0.163760215	8.637935

Untuk mengukur manfaat praktis penggunaan TCN dibandingkan pendekatan klasik, evaluasi dilakukan dengan membandingkan kinerja absolut model baseline terbaik pada setiap kombinasi skenario–target (Tabel 1) dengan kinerja model TCN beserta selisih perbaikannya (Δ) pada metrik utama, di mana perbandingan dilakukan secara konsisten per skenario (ALL, TECH, FUND) dan per target (High_next dan Low_next). Metrik MAE dan RMSE dilaporkan dalam satuan Rupiah (setelah konversi dari ribu Rupiah), sMAPE dalam persentase, dan MASE tanpa satuan, dengan Δ didefinisikan sebagai selisih Baseline – TCN sehingga nilai positif menunjukkan keunggulan TCN. Hasil pada Tabel 1 menunjukkan bahwa baseline terbaik didominasi oleh model Ridge untuk skenario ALL dan TECH serta Linear untuk FUND, dengan sMAPE baseline relatif tinggi terutama pada target Low dan skenario FUND, yang menandakan ruang perbaikan yang besar.

Selanjutnya, Tabel 2 memperlihatkan bahwa TCN secara konsisten mengungguli baseline terbaik pada seluruh kombinasi skenario×target, dengan pola yang stabil: TECH unggul untuk High_next dan ALL paling efektif untuk Low_next. Perbaikan terbesar tercatat pada Low_next–ALL dengan Δ MAE sekitar Rp 337, Δ RMSE sekitar Rp 494, dan Δ MASE sekitar 2,14 disertai penurunan sMAPE sebesar $\pm 4,10$ poin persentase, sementara peningkatan signifikan pada High_next–TECH tercermin dari Δ MAE sekitar Rp 159, Δ RMSE sekitar Rp 205, dan Δ MASE sekitar 1,12. Sebaliknya, skenario FUND tetap menjadi yang terlemah karena meskipun Δ bernilai positif (TCN tetap lebih baik daripada baseline linearnya), error absolut TCN masih relatif tinggi. Konsistensi Δ positif di seluruh baris menegaskan keunggulan TCN secara menyeluruh, yang juga selaras dengan dinamika pelatihan di mana skenario ALL dan TECH menunjukkan konvergensi yang sehat, sedangkan FUND dibatasi oleh keterbatasan informasi fitur.



Gambar 5 Chart Loss Scenario ALL

Scenario ALL loss. train_loss turun tajam lalu stabil; *val_loss* menurun & membentuk *plateau*; *best checkpoint* $\approx$ *epoch 11*.

Hasil analisis dinamika pelatihan pada Gambar 4.10–4.15 menunjukkan pola konvergensi yang konsisten antar skenario, ditandai oleh penurunan *train_loss* yang stabil, *val_loss* yang membentuk *plateau*, serta penyesuaian *learning rate* yang hanya memicu perbaikan minor pasca-*plateau*; pada skenario ALL, *step-decay learning rate* mendukung konvergensi stabil hingga *checkpoint* terbaik, sedangkan pada FUND meskipun *train_loss* menurun, *val_loss* relatif tinggi dan datar dengan gap *train–val* yang lebar (*best checkpoint* sekitar *epoch 5*),

mengindikasikan keterbatasan informasi fitur yang tidak dapat diatasi oleh penjadwalan learning rate semata. Sebaliknya, skenario TECH memperlihatkan train_loss yang turun konsisten, val_loss mencapai minimum lokal lalu stabil (best checkpoint sekitar epoch 9), serta jadwal learning rate bertahap yang menjaga stabilitas tanpa gejala overfitting, selaras dengan kinerja terbaik pada target High_next. Setelah konvergensi pelatihan, evaluasi visual pada TEST split melalui Gambar 4.16–4.21 memperlihatkan bahwa prediksi ALL dan TECH umumnya mampu mengikuti tren data aktual namun mengalami lag di titik balik (puncak/lembah) dan efek smoothing, dengan tracking terbaik pada TECH–High (konsisten dengan MAE 364,862 dan sMAPE 3,83%), sementara kinerja pada target Low menunjukkan miss yang membesar saat fase penurunan tajam, terutama pada TECH–Low dan FUND. Selanjutnya, evaluasi conformal intervals pada tingkat nominal L90 dan L95 (Tabel 4.6–4.7) menunjukkan bahwa FUND–High paling dekat dengan target Coverage baik pada L90 (93,1%, deviasi +3,1 p.p.) maupun L95 (93,1%, deviasi –1,9 p.p.), namun dengan AIW paling lebar, sedangkan ALL dan TECH menawarkan efisiensi band yang lebih baik ($AIW \approx Rp\ 0,88\text{--}1,16$) namun Coverage TEST masih di bawah nominal, khususnya pada target Low. Temuan ini menyiratkan arah perbaikan yang jelas: fokuskan re-calibration kuantil dan/atau kalibrasi berbasis volatilitas pada konfigurasi yang sudah efisien seperti TECH–High dan ALL–Low agar Coverage mendekati nominal dengan kenaikan AIW yang minimal, sekaligus menguatkan interpretasi metrik point forecast dan menjadi landasan pembahasan lanjutan pada aspek Coverage dan AIW.

Kesimpulan singkat. Hasil menunjukkan dua kekuatan komplementer: (i) kedekatan ke nominal pada FUND–High sebagai bukti bahwa skema kalibrasi dapat mencapai target, dan (ii) efisiensi AIW pada ALL/TECH sebagai basis pita yang ekonomis. Langkah berikutnya cukup berupa re-calibration ringan moderate untuk membawa konfigurasi efisien tersebut lebih dekat ke Coverage nominal.

Dalam penelitian ini, penggunaan L90 dan L95 bertujuan menyajikan prediction interval sehingga keluaran model tidak hanya berupa point forecast High_next dan Low_next, tetapi juga merefleksikan ketidakpastian prediksi pada horizon bulanan yang volatil; kualitas interval kemudian divalidasi melalui Coverage untuk memastikan bahwa tingkat nominal 90% dan 95% benar-benar menangkap proporsi observasi aktual yang sepadan pada data uji, sehingga pelaporan L90/L95 dan Coverage menjadi krusial agar hasil model lebih reliabel, interpretabel, dan aplikatif dalam pengambilan keputusan. Selanjutnya, untuk menjawab RQ3, kontribusi fitur terhadap akurasi prediksi pada model TCN dianalisis menggunakan Permutation Importance pada TEST split dengan skema time-based tanpa shuffle, di mana kenaikan MAE (ΔMAE , dalam Rupiah) akibat pengacakan fitur digunakan sebagai indikator tingkat kepentingan fitur.

Hasil pada skenario ALL (Tabel 4.8) menunjukkan bahwa untuk target High_next, fitur paling dominan adalah indikator tren jangka pendek–menengah dan volatilitas, khususnya EMA_6, BOLL_LO_12, SMA_6, EMA_12, dan BOLL_UP_12, yang menegaskan peran kuat sinyal tren dan pita Bollinger dalam memodelkan puncak harga bulan berikutnya. Sementara itu, untuk target Low_next, kontribusi terbesar berasal dari kombinasi EMA_6, IHSI_Level, MACD_HIST, BOLL_LO_12, dan EMA_3, yang mengindikasikan bahwa selain tren cepat, level pasar secara luas dan momentum memiliki peran penting dalam menangkap dinamika penurunan harga. Secara keseluruhan, temuan ini menegaskan bahwa indikator teknikal

merupakan kontributor utama untuk High_next, sedangkan prediksi Low_next lebih diuntungkan oleh kombinasi fitur teknikal dan makro, selaras dengan hasil RQ2, serta menjadi dasar bagi analisis lanjutan melalui ablation dan stability test untuk menilai ketahanan dan kebutuhan perampingan fitur.

Berdasarkan hasil pada sub-bab 4.1, 4.2, 4.3, ketiga rumusan masalah (RQ1–RQ3) terjawab sebagai berikut. Dari sisi RQ1, penelitian ini berhasil merancang dan menerapkan model TCN untuk prediksi High_next dan Low_next bulanan BBKA dalam sebuah pipeline replikabel.

Arsitektur terdiri dari tiga residual blocks dengan channels [32, 32, 32]. Setiap blok memuat causal 1-D dilated convolution (hanya melihat masa lalu), aktivasi, dan residual skip untuk stabilitas gradien; dilasi meningkat per blok (1–2–4) guna memperluas receptive field tanpa menambah panjang filter, sedangkan causal padding mempertahankan panjang urutan agar tidak terjadi look-ahead leakage.

Arsitektur ini (TCN) diintegrasikan ke alur yang konsisten: dimulai dari validasi & penyelarasan kalender bulanan → feature engineering (MA/EMA, RSI, Stochastic %K/%D, Bollinger Mid/Up/Lo, MACD–Signal, Monthly Return, Rolling Volatility) serta faktor fundamental/ eksternal (IHSG, USD/IDR, BI Rate) → split time-based tanpa shuffle (fit scaler di TRAIN) → windowing → pelatihan → evaluasi. Hasil eksperimen menunjukkan model stabil dan siap re-train/inferensi saat data diperbarui.

Menjawab RQ2, akurasi TCN pada target High terbaik diperoleh pada skenario TECH dengan MAE 364.862, RMSE 447.598, sMAPE 3,83%, dan MASE 2,56; performa ALL–High sangat dekat (MAE 370.651; sMAPE 3,82%). Dibanding baseline Ridge, TECH–High membaik secara actual (MAE 523,95 → 364,86, selisih –159,09; RMSE 652,74 → 447,60, selisih –205,14; sMAPE 5,38% → 3,83%, perbaikan 1,55 p.p.).

Pada target Low, akurasi terbaik dicapai ALL–Low (MAE 680.658; RMSE 746.583; sMAPE 7,78%; MASE 4,32). Terhadap baseline Ridge, perbaikan ALL–Low juga jelas (MAE 1.017,87 → 680,66, selisih –337,21; sMAPE 11,88% → 7,78%, perbaikan 4,10 p.p.).

Untuk TECH–Low, meskipun metrik lebih lemah (MAE 1.360,02; sMAPE 16,38%), pola kurva pada chart TEST relatif mirip dengan aktual namun ter-smooth dan ber-amplitudo lebih rendah, terutama saat drawdown. Hal ini menunjukkan ruang perbaikan melalui post-hoc scaling atau re-weighting loss agar puncak-lembah mengikuti aktual dan metrik turut membaik. Dari sisi interval, cakupan L90 terbaik diperoleh FUND–High (93,1%, deviasi +3,1 p.p., AIW $\approx$ 2.582), sedangkan ALL–High 75,9% (–14,1 p.p.) dan ALL–Low 65,5% (–24,5 p.p.) masih under-coverage; pola serupa tampak pada L95 (mis. FUND–High 93,1% $\approx$ –1,9 p.p., sementara ALL–Low 62,1% dan TECH–Low 58,6% jauh di bawah target). Temuan ini menyarankan kalibrasi interval untuk target Low.

Terkait RQ3, analisis Permutation Importance pada skenario ALL menegaskan dominasi sinyal momentum/ trend dan batas volatilitas. Untuk High_next, tiga teratas adalah EMA_6 (Rank 1, Δ MAE +89,76), BOLL_LO_12 (Rank 2, +36,50), dan SMA_6 (Rank 3, +32,49). Untuk Low_next, EMA_6 kembali dominan (Rank 1, +52,95), diikuti IHSG_LEVEL (Rank 2, +35,31), dan MACD_Hist (Rank 3, +28,43). Konsistensi ini sejalan dengan pengamatan grafik: model telah menangkap bentuk pergerakan (khususnya pada TECH–Low), tetapi skalanya yang berkaitan dengan sinyal volatilitas perlu dinaikkan agar kesesuaian amplitudo terhadap aktual meningkat dan tercermin pada metrik.

Secara keseluruhan, RQ1 menunjukkan bahwa arsitektur TCN kausal ber-dilasi (3 blok; [32,32,32]) dapat dioperasionalkan dalam pipeline bulanan yang replikabel; RQ2 membuktikan kelayakan akurasi terbaik TECH–High untuk High dan ALL–Low untuk Low, keduanya mengungguli baseline, serta menyoroti kebutuhan kalibrasi interval, terutama pada Low; dan RQ3 memetakan fitur kunci (EMA, Bollinger–lower, SMA) yang menjelaskan mengapa pola sudah tepat tetapi amplitudo khususnya pada Low, masih perlu penyesuaian.

Impilkasi

Temuan pada Bab 4.2 (point forecast) dan (conformal intervals L90/L95) menunjukkan bahwa model TCN mampu memberikan output berupa estimasi titik sekaligus rentang ketidakpastian yang terkalibrasi. Bagian ini menautkan hasil tersebut ke dua ranah implikasi: (i) teoritis: keterjelasan rancangan arsitektur dan pipeline yang replikabel untuk data bulanan; dan (ii) praktis: kegunaan langsung untuk pengambilan keputusan yang sadar-risiko.

KESIMPULAN

Penelitian ini berhasil merancang arsitektur TCN dan mengoperasionalkan TCN model dalam pipeline bulanan yang replikabel dan kausal untuk memprediksi High_next dan Low_next saham BBKA. Arsitektur terbukti stabil dan siap digunakan kembali untuk re-train maupun inferensi ketika data diperbarui.

Dari sisi kinerja, TCN layak untuk horizon bulanan: skenario TECH memberikan hasil terkuat untuk High, sementara ALL unggul untuk Low; keduanya melampaui baseline linear. Secara visual, model telah menangkap pola pergerakan pada data uji, meskipun prediksi Low masih menunjukkan amplitudo yang perlu ditingkatkan dan interval prediksi (L90/L95) perlu kalibrasi tambahan pada periode volatil.

Kontribusi fitur menegaskan peran dominan sinyal momentum/trend (EMA/SMA, MACD, RSI/Stochastic) dan volatilitas/batas harga (Bollinger, rolling volatility), sementara indikator makro (IHSG, USD/IDR, BI Rate) bersifat komplementer. Secara keseluruhan, penelitian ini menyajikan arsitektur TCN yang teruji, kerangka evaluasi yang transparan, dan UI uji yang mendukung replikasi serta audit. Arah peningkatan diarahkan pada penyetelan amplitudo untuk Low, kalibrasi interval, serta penguatan arsitektur dan fitur, yang dirinci pada 5.2 Saran.

DAFTAR PUSTAKA

- Aisya, Sarjan, S., Setiawanti, N. A., & Marjohan, M. (2025). Capital Market in Indonesia. *Indonesian Development of Economics and Administration Journal*, 3(3), 226–230.
- Akaçık, Ö. (t.t.). ModernTCN Revisited: A Critical Look at the Experimental Setup in General Time Series Analysis Mark Hoogendoorn. <https://github.com/onderakacik/RE-ModernTCN>
- Alamsyahbana, M., Saputra, N., Fauzi, F., Antania, L., & Setiawan, E. (2023, Juni 22). Good to Great Effect – At Bank Sectors in Indonesian Capital Market. <https://doi.org/10.4108/eai.17-12-2022.2333268>
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. <http://arxiv.org/abs/1803.01271>

- Barua, M., Kumar, T., Raj, K., & Roy, A. M. (2024). Comparative Analysis of Deep Learning Models for Stock Price Prediction in the Indian Market. *FinTech*, 3(4), 551–568. <https://doi.org/10.3390/fintech3040029>
- Dai, W., An, Y., & Long, W. (2021). Information Technology and Quantitative Management (ITQM 2020&2021) Price change prediction of ultra high frequency financial data based on temporal convolutional network. [www.sciencedirect.com](http://www.sciencedirect.com/locate/procedia)www.elsevier.com/locate/procedia
- Du, S., & Shen, H. (2024). Reinforcement Learning-Based Multimodal Model for the Stock Investment Portfolio Management Task. *Electronics (Switzerland)*, 13(19). <https://doi.org/10.3390/electronics13193895>
- Fajou, J. (2021a). Forecasting Gold Prices Using Temporal Convolutional Networks.
- Fajou, J. (2021b). Forecasting Gold Prices Using Temporal Convolutional Networks.
- Gibbs, I., & Candès, E. (2021). Adaptive Conformal Inference Under Distribution Shift. <http://arxiv.org/abs/2106.00170>
- Gil, G. L., Duhamel-Seblin, P., & McCarren, A. (2024). An Evaluation of Deep Learning Models for Stock Market Trend Prediction. <http://arxiv.org/abs/2408.12408>
- Google Finance. (2025). Index Harga Saham BBKA. <https://www.google.com/finance/quote/BBKA:IDX?hl=id>.
- Guidotti, R., Monreale, A., Ruggieri, S., Turini, F., Pedreschi, D., & Giannotti, F. (2018). A Survey Of Methods For Explaining Black Box Models. <http://arxiv.org/abs/1802.01933>
- Harry Akbar Al Hakim. (2021). PREDIKSI TREN PERGERAKAN HARGA SAHAM MENGGUNAKAN ALGORITMA TEMPORAL CONVOLUTIONAL NETWORK (TCN).
- Hodson, T. O. (2022). Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not. *Dalam Geoscientific Model Development (Vol. 15, Nomor 14, hlm. 5481–5487)*. Copernicus GmbH. <https://doi.org/10.5194/gmd-15-5481-2022>
- idx.co.id. (2025, September 4). Jumlah Investor Lampau 18 Juta, Cerminkan Stabilitas Pasar Modal Indonesia. [idx.co.id. https://www.idx.co.id/id/berita/siaran-pers/2442](https://www.idx.co.id/id/berita/siaran-pers/2442)
- Jange, B. (2022). Prediksi Harga Saham Bank BCA Menggunakan XGBoost. *ARBITRASE: Journal of Economics and Accounting*, 3(2), 231–237. <https://doi.org/10.47065/arbitrase.v3i2.495>
- Jange, B. (2023). Prediksi Volatilitas Indeks Harga Saham Gabungan Menggunakan GARCH. *ARBITRASE: Journal of Economics and Accounting*, 4(1), 1–6. <https://doi.org/10.47065/arbitrase.v4i1.1122>
- Janssen, P. (2022). Attention based Temporal Convolutional Network for stock price prediction. <https://github.com/PaoloJ36/ATCN/>.
- Lara-Benítez, P., Carranza-García, M., Luna-Romera, J. M., & Riquelme, J. C. (2020). Temporal convolutional networks applied to energy-related time series forecasting. *Applied Sciences (Switzerland)*, 10(7). <https://doi.org/10.3390/app10072322>
- Lee, J., Kim, R., Koh, Y., & Kang, J. (2019). Global Stock Market Prediction Based on Stock Chart Images Using Deep Q-Network. <https://doi.org/10.1109/ACCESS.2019.2953542>
- Liu, Y., Huang, X., Xiong, L., Chang, R., Wang, W., & Chen, L. (2025). Stock price prediction with attentive temporal convolution-based generative adversarial network. *Array*, 25. <https://doi.org/10.1016/j.array.2025.100374>

- Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. <http://arxiv.org/abs/1705.07874>
- Mahendra, K., Satyahadewi, N., & Perdana, H. (2022). ANALISIS TEKNIKAL SAHAM MENGGUNAKAN INDIKATOR MOVING AVERAGE CONVERGENCE DIVERGENCE (MACD). Dalam Buletin Ilmiah Math. Stat. dan Terapannya (Bimaster) (Vol. 11, Nomor 1).
- Prayogi, K., Gata, W., & Kussanti, D. P. (t.t.). Prediksi Harga Saham Bank Central Asia Menggunakan Algoritma Deep Learning GRU.
- Purnama Sari, E., Bachri, S. M., Atnang, M., Fajar, N., Studi Teknologi Informasi, P., Sains Teknologi dan Kesehatan, F., Sains Teknologi dan Kesehatan, I., & Kendari, A. (2024). Studi Literatur Deep Learning dan Machine Learning untuk Analisis dan Prediksi Pasar Saham: Metodologi, Representasi Data dan Studi Kasus. Dalam Jurnal Teknologi dan Sains Modern (Vol. 1, Nomor 1). <https://journal.scitechgrup.com/index.php/jtsm>
- Rijken Irahadi, D., Stevani Sianturi, M., Suk Kim, S., Kunci, K., Pergerakan, R.-R., Kekuatan Relatif, I., & Oscillator, S. (t.t.). PENGGUNAAN INDIKATOR ANALISA TEKNIKAL PADA PASAR SAHAM DI INDONESIA.
- Rohman Tiovandi, M., & Susyanti, J. (2024). Anailisis Dengan Indikator Bollinger Band dan Stochastic Oscillator Pada Saham Serta Fundamental Perusahaan LQ 45 Sub Sektor Perbankan. Jurnal Ilmiah Multidisiplin, 1(6), 249–257. <https://doi.org/10.62017/merdeka>
- Romano, Y., Patterson, E., & Candès, E. J. (2019). Conformalized Quantile Regression. <http://arxiv.org/abs/1905.03222>
- Rouf, N., Malik, M. B., Arif, T., Sharma, S., Singh, S., Aich, S., & Kim, H. C. (2021). Stock market prediction using machine learning techniques: A decade survey on methodologies, recent developments, and future directions. Dalam Electronics (Switzerland) (Vol. 10, Nomor 21). MDPI. <https://doi.org/10.3390/electronics10212717>
- Setiawan, B., Purnamasari, E., & Ulum, M. B. (2020). Macroeconomic Indicators and Stock Market Development on Economic Growth: Empirical Evidence from ASEAN Countries. SRIWIJAYA INTERNATIONAL JOURNAL OF DYNAMIC ECONOMICS AND BUSINESS, 271–282. <https://doi.org/10.29259/sijdeb.v3i4.271-282>
- Shobri, M. Q., Baihaqi, M. A., Kubro, P. B. Al, Andiyani, R. A., Istikhomah, F., Handayani, P. T., Isa, M., & Nuryana, I. (2023). Model Analisis Harga Saham Sektor Finansial PT. Bank Central Asia Tbk. (BBCA). Jurnal Keilmuan dan Keislaman, 260–269. <https://doi.org/10.23917/jkk.v2i4.170>
- Sun, G., & Deng, S. (2025). Financial Time Series Forecasting: A Comparison Between Traditional Methods and AI-Driven Techniques. Journal of Computer, Signal, and System Research, 2(2), 86–93. <https://doi.org/10.71222/339b9812>
- Valiant, K., Lukito, Y., & Santosa, R. G. (2019). Sistem Prediksi Harga Saham LQ45 Dengan Random Forest Classifier. 2. <https://doi.org/10.21460/jutei.2019.32.187>
- Wathani, M. N., Kusrini, K., & Kusnawi, K. (2023). Prediksi Tren Pergerakan Harga Saham PT Bank Central Asia Tbk, Dengan Menggunakan Algoritma Long Shot Term Memory (LSTM). Infotek: Jurnal Informatika dan Teknologi, 6(2), 502–512. <https://doi.org/10.29408/jit.v6i2.19824>
- Zaffran, M., Dieuleveut, A., Féron, O., Goude, Y., & Josse, J. (2022). Adaptive Conformal

Copyright holder:

Nanda Darma Wirawan, Eddy Muntina Dharma, Made Adi Paramartha Putra (2026)

First publication right:

Syntax Literate: Jurnal Ilmiah Indonesia

This article is licensed under:

